Politechnika Warszawska
Wydział Matematyki
i Nauk Informacyjnych

Cechy Sygnału
Audio w Czasie

Raport z projektu

Analiza i przetwarzanie dźwięku

Małgorzata Dżaman

nr indeksu: 327241

WARSZAWA 2025

Contents

1 Wstęp **3**

2 Środowisko programistyczne i architektura rozwiązania **4**

3 Implementacja programu **5**

3.1 Wczytywanie plików WAV 5

3.2 Segmentacja sygnału na ramki 5

3.3 Cechy frame-level 6

3.4 Interfejs użytkownika 6

3.5 Eksport danych 7

4 Przebieg eksperymentów **8**

4.1 Format danych wejściowych 8

4.2 Scenariusz analizy 9

5 Analiza wyników **10**

5.1 Przebieg czasowy i detekcja ciszy 10

5.2 RMS i STE 10

5.3 ZCR 11

5.4 Estymacja F_0 11

5.4.1 Zachowanie dla różnych typów sygnału 11

5.4.2 ACF vs AMDF 11

5.5 Wartości przykładowych cech dla wybranych słów 12

6 Porównanie nagrań różnych mówców **13**

7 Wnioski końcowe **14**

1 Wstęp

Analiza sygnałów audio stanowi istotny obszar współczesnego przetwarzania sygnałów, znajdujący zastosowanie w wielu dziedzinach, takich jak rozpoznawanie mowy, synteza mowy, systemy multimedialne, analiza muzyki czy systemy bezpieczeństwa (np. identyfikacja mówcy). Jednym z podstawowych podejść do analizy sygnału dźwiękowego jest analiza w dziedzinie czasu, która pozwala bezpośrednio badać zmiany sygnału w czasie oraz jego lokalne właściwości.

Sygnał mowy jest sygnałem niestacjonarnym, co oznacza, że jego właściwości zmieniają się w czasie. Z tego powodu w analizie stosuje się podejście krótkookresowe, polegające na dzieleniu sygnału na krótkie fragmenty - ramki. Dzięki temu możliwe jest wyznaczanie parametrów opisujących lokalne cechy sygnału, takich jak energia, liczba przejść przez zero czy obecność tonu podstawowego.

Cechy wyznaczane w dziedzinie czasu, takie jak RMS (Volume), STE (Short-Time Energy) oraz ZCR (Zero Crossing Rate), dostarczają istotnych informacji o charakterze sygnału. Umożliwiają one między innymi:

- rozróżnianie fragmentów dźwięcznych i bezdźwięcznych,
- wykrywanie ciszy,
- analizę struktury fonetycznej wypowiedzi,
- przygotowanie danych do dalszych etapów przetwarzania, takich jak rozpoznawanie mowy.

Dodatkowo analiza w dziedzinie czasu pozwala na estymację częstotliwości tonu podstawowego F_0, która jest jednym z najważniejszych parametrów opisujących sygnał mowy. Parametr ten jest bezpośrednio związany z wysokością głosu i odgrywa kluczową rolę w identyfikacji mówcy oraz syntezie mowy.

Celem projektu było opracowanie aplikacji okienkowej umożliwiającej analizę sygnału audio w dziedzinie czasu. Projekt został zrealizowany w języku C# z wykorzystaniem technologii WinForms jako interfejsu użytkownika. Zakres projektu obejmował implementację wybranych cech sygnału audio na poziomie ramki, detekcję ciszy, estymację częstotliwości tonu podstawowego w dziedzinie czasu z użyciem autokorelacji i funkcji AMDF oraz prezentację wyników w postaci wykresów i wartości liczbowych.
Aplikacja umożliwia wizualizację przebiegu sygnału, analizę jego parametrów w czasie oraz interpretację wyników dla różnych typów nagrań. Dodatkowo została rozszerzona o zapis wyznaczonych parametrów do pliku CSV, co pozwala na dalszą analizę danych poza aplikacją.

2 Środowisko programistyczne i architektura rozwiązania

Projekt został wykonany w środowisku Visual Studio w języku C# z użyciem platformy WinForms. Interfejs użytkownika zaprojektowano jako pojedyncze okno aplikacji z zakładkami. Do rysowania wykresów została wykorzystana biblioteka ScottPlot, przy czym wszystkie cechy syganłu w dziedzinie czasu zostały obliczone ręcznie na podstawie wzorów. Kod aplikacji został podzielony na kilka logicznych części:

- **WavReader** – odpowiedzialny za ręczne wczytywanie pliku WAV PCM 16-bit,
- **Framing** – odpowiedzialny za dzielenie sygnału na ramki,
- **FeatureExtractor / FrameFeatures** – odpowiedzialny za obliczanie cech na poziomie ramki,
- **PitchDetector** – odpowiedzialny za estymację F_0 metodą autokorelacji i AMDF,
- **CsvExporter** – odpowiedzialny za zapis wyników do pliku CSV,
- **Form1** – interfejs użytkownika i integracja wszystkich modułów.

3 Implementacja programu

3.1 Wczytywanie plików WAV

Program obsługuje pliki WAV PCM 16-bit w trybie mono i stereo. W przypadku sygnału stereofonicznego kanały są uśredniane do postaci mono. Odczyt danych realizowany jest ręcznie na poziomie nagłówka RIFF/WAVE i bloku `data`, bez używania gotowych bibliotek do analizy dźwięku.

Po wczytaniu pliku program odczytuje i prezentuje użytkownikowi:

- nazwę pliku,
- częstotliwość próbkowania,
- liczbę kanałów,
- rozdzielczość bitową,
- czas trwania nagrania.

3.2 Segmentacja sygnału na ramki

Sygnał wejściowy jest dzielony na ramki o długości 20 ms. Dla częstotliwości próbkowania 22050 Hz daje to $N = 441$ próbek na ramkę. Przesunięcie pomiędzy kolejnymi ramkami ustawiono na połowę długości ramki, co odpowiada nakładaniu 50%.
Dodatkowo w implementacji zastosowano opcjonalne okno Hamminga przed obliczaniem wybranych cech i parametrów związanych z F_0, co ogranicza wpływ nieciągłości na brzegach ramki.

3.3 Cechy frame-level

Dla każdej ramki obliczane są następujące parametry:

- Volume / RMS,
- STE,
- ZCR,
- flaga ciszy (`IsSilence`),
- F_0 wyznaczone metodą autokorelacji,
- F_0 wyznaczone metodą AMDF,
- flaga `voiced/unvoiced`.

3.4 Interfejs użytkownika

Interfejs aplikacji składa się z:

- menu File umożliwiającego otwarcie pliku WAV i eksport wyników do CSV,
- panelu informacyjnego z danymi o pliku,
- zakładek:
  - **Waveform** – przebieg czasowy sygnału wraz z zaznaczoną ciszą i wybraną ramką,
  - **Frame features** – wykres wybranej cechy (RMS, STE lub ZCR),
  - **Pitch ACF** – kontur częstotliwości tonu podstawowego wyznaczonej metodą autokorelacji,
  - **Pitch AMDF** – kontur częstotliwości tonu podstawowego wyznaczonej metodą AMDF,
- suwaka wyboru ramki,
- panelu tekstowego pokazującego szczegółowe wartości dla bieżącej ramki.

Na rysunku 1 przedstawiono główne okno aplikacji po wczytaniu pliku WAV. Interfejs został zaprojektowany w formie zakładek, co umożliwia oddzielną analizę przebiegu czasowego, cech frame-level oraz estymacji tonu podstawowego metodami ACF i AMDF.

Figure 1: Główne okno aplikacji po wczytaniu nagrania

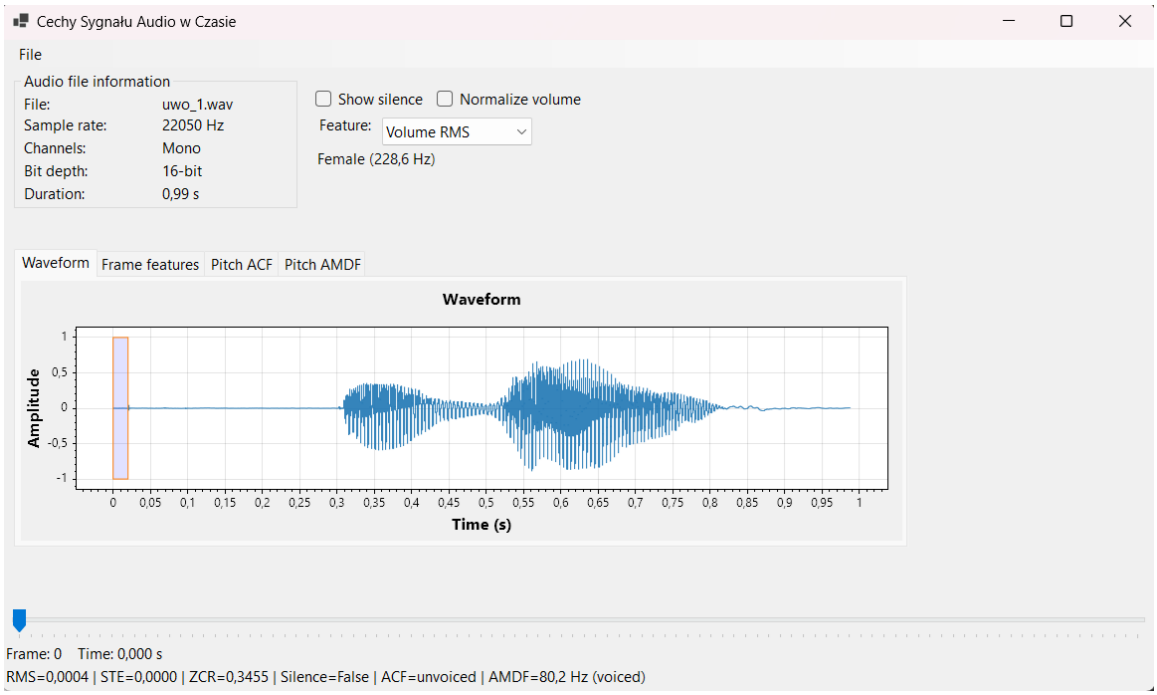

3.5 Eksport danych

Program został rozszerzony o możliwość zapisu wyników do pliku CSV. Zapisywane są:

- numer ramki,
- czas początku i końca ramki,
- RMS,
- STE,
- ZCR,
- informacja o ciszy,
- F_0 z ACF,
- F_0 z AMDF,

- informacja voiced/unvoiced.

Domyślna nazwa pliku wynikowego ma postać `nazwa_pliku_wav_features.csv`.

4 Przebieg eksperymentów

4.1 Format danych wejściowych

W badaniu wykorzystano nagrania pochodzące od dziewięciu mówców, z czego osiem osób stanowili mężczyźni, a jedna osoba była kobietą. Oznacza to, że udział mężczyzn w badanej grupie wynosił około 88.9%, natomiast udział kobiet około 11.1%. Wykres 2 przedstawia procentowy udział płci w nagraniach.

Figure 2: Struktura grupy badanych mówców.

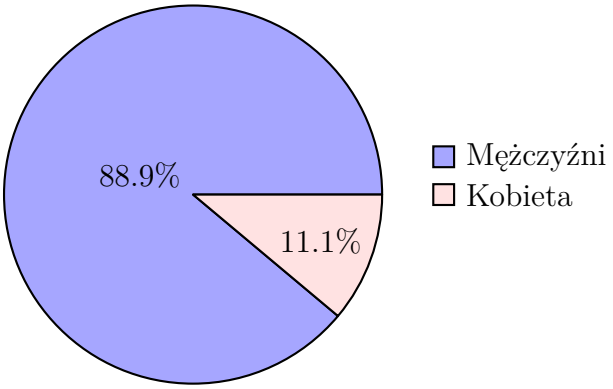

Analizowane nagrania pochodziły z przygotowanego korpusu nagrań. Wszystkie pliki były monofoniczne, próbkowane z częstotliwością 22050 Hz i zapisane jako 16-bit PCM. Nagrania zostły podzielone na znormalizowane oraz nieznormalizowane. Na podstawie korpusu nagrań można wyróżnić pięć głównych kategorii materiału:

- liczby(11),
- logatomy(15),
- wyrazy łatwe(5),
- wyrazy trudne(5),
- zdania(2)

Przyjmując, że każdy mówca nagrał cały zestaw, proporcje poszczególnych typów nagrań w całym zbiorze pozostają takie same jak proporcje elementów korpusu. Największą część materiału stanowiły logatomy, natomiast najmniejszą - zdania. Wykres 3 obrazuje procentowy udział każdej kategorii w odniesieniu do wszystkich nagrań

Figure 3: Procentowy udział poszczególnych kategorii nagrań w korpusie.

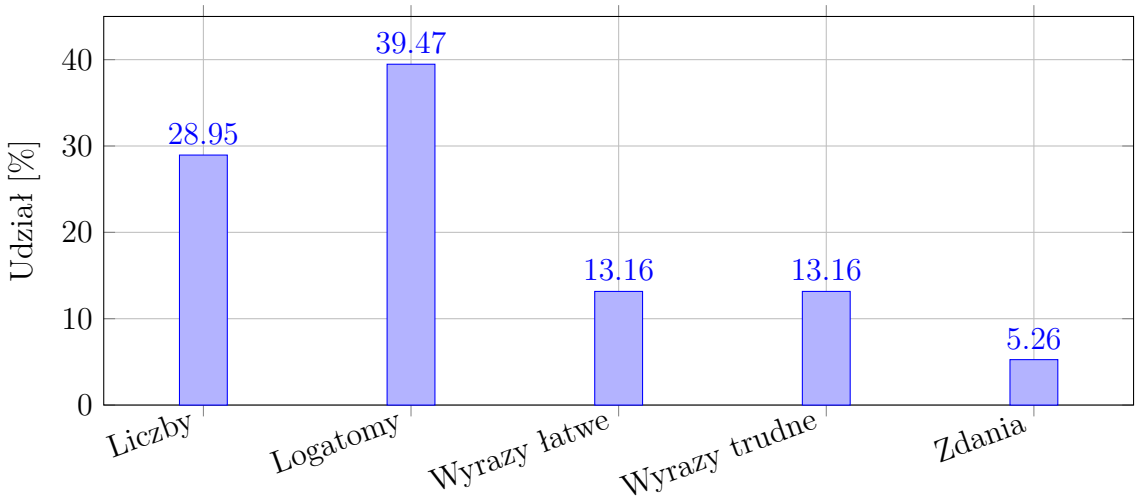

Z punktu widzenia analizy sygnału taki dobór materiału był korzystny, ponieważ obejmował zarówno bardzo krótkie słowa izolowane, jak i dłuższe wypowiedzi. Logatomy umożliwiały obserwację prostych struktur fonetycznych i kontrolowanych przejść pomiędzy głoskami, natomiast wyrazy trudne i zdania pozwalały analizować bardziej złożone przebiegi energii, ZCR oraz tonu podstawowego.

4.2 Scenariusz analizy

Dla każdego nagrania wykonywano następujące kroki, w celu przeanalizowania sygnału na podstawie cech audio w czasie :

1. wczytanie pliku WAV do aplikacji,
2. podział sygnału na ramki (20 ms, 50% overlap),
3. obliczenie cech frame-level (RMS, STE, ZCR),
4. detekcja ciszy,
5. estymacja F_0 metodą ACF i AMDF,

6. wizualizacja wyników,
7. analiza różnic pomiędzy fragmentami dźwięcznymi i bezdźwięcznymi,
8. eksport wyników do pliku CSV.

5 Analiza wyników

5.1 Przebieg czasowy i detekcja ciszy

Dla wszystkich analizowanych nagrań poprawnie wykrywano fragmenty ciszy, które pojawiały się zazwyczaj:

- przed rozpoczęciem wypowiedzi,
- po jej zakończeniu,
- pomiędzy słowami w zdaniach.

W przypadku zdań, takich jak *„Ala ma rudego kota”*, widoczne były wyraźne przerwy pomiędzy słowami, które zostały poprawnie oznaczone jako cisza.

5.2 RMS i STE

Dla wszystkich analizowanych słów obserwowano zgodną zależność:

- najwyższe wartości RMS i STE występowały dla samogłosek,
- niższe wartości pojawiały się dla spółgłosek bezdźwięcznych.

Przykłady:

- **„kot”** – maksimum energii dla samogłoski *o*,
- **„pies”** – wyraźny wzrost energii dla *ie*,
- **„samochód”** – kilka lokalnych maksimów odpowiadających kolejnym sylabom,
- **„kwiat”** – krótki sygnał z jednym dominującym maksimum,

W przypadku dłuższych słów (np. *„przetwarzanie”*) energia była rozłożona na kilka segmentów odpowiadających kolejnym sylabom.

5.3 ZCR

ZCR wykazywał bardzo wyraźne różnice pomiędzy typami głosek:

- wysokie wartości ZCR dla spółgłosek bezdźwięcznych (np. *k*, *t*, *s*),
- niskie wartości dla samogłosek (np. *a*, *o*, *e*).

Przykłady:

- **„chrząszcz”** – bardzo wysokie ZCR w większości sygnału (szumowy charakter),
- **„dźwięk”** – zróżnicowany ZCR, szczególnie wysoki dla końcowego *k*,
- **„gum”, „bub”** – wyraźne różnice między spółgłoskami i samogłoską.

5.4 Estymacja F_0

5.4.1 Zachowanie dla różnych typów sygnału

- dla samogłosek (*o*, *a*, *e*) obserwowano stabilne wartości F_0,
- dla spółgłosek bezdźwięcznych (*k*, *t*, *s*) F_0 było zerowane,
- dla logatomów typu VCV (np. *aba*) F_0 było obecne niemal przez cały sygnał,
- dla logatomów CVC (np. *gum*) F_0 pojawiało się głównie w środkowej części.

5.4.2 ACF vs AMDF

- ACF czasami zawyżało F_0 (wybór harmonicznej),
- AMDF czasami zaniżało F_0 (wybór większego opóźnienia),
- po zastosowaniu progów i ograniczeń zakresu wyniki obu metod były bardziej stabilne.

5.5 Wartości przykładowych cech dla wybranych słów

W celu lepszego zobrazowania działania algorytmów zestawiono wartości przykładowych cech dla wybranych słów z korpusu.

Table 1: Przykładowe wartości cech dla wybranych nagrań

Słowo	**Fragment**	**RMS**	**STE**	**ZCR**
kot	k (bezdźwięczny)	niskie	niskie	wysokie
	o (samogłoska)	wysokie	wysokie	niskie
	t (bezdźwięczny)	niskie	niskie	wysokie
pies	p (bezdźwięczny)	niskie	niskie	wysokie
	ie (samogłoska)	wysokie	wysokie	niskie
	s (szumowy)	niskie	niskie	bardzo wysokie
kwiat	kw (bezdźwięczne)	niskie	niskie	wysokie
	ia (samogłoska)	wysokie	wysokie	niskie
	t (bezdźwięczny)	niskie	niskie	wysokie
samochód	sa (samogłoska)	średnie	średnie	niskie
	mo (samogłoska)	wysokie	wysokie	niskie
	ch (szumowy)	niskie	niskie	wysokie
chrząszcz	chrz (szumowy)	niskie	niskie	bardzo wysokie
	ą (samogłoska)	średnie	średnie	niskie
	szcz (szumowy)	niskie	niskie	bardzo wysokie
aba	a (samogłoska)	wysokie	wysokie	niskie
	b (dźwięczna)	średnie	średnie	średnie
	a (samogłoska)	wysokie	wysokie	niskie

Wartości przedstawione w tabeli wynikają z obserwacji wykresów generowanych przez aplikację. Ogólnie można powiedzieć, że:

- samogłoski charakteryzują się wysoką energią (RMS, STE) oraz niskim ZCR,
- spółgłoski bezdźwięczne mają niską energię i wysoki ZCR,
- ton podstawowy F_0 występuje głównie w fragmentach dźwięcznych,
- fragmenty szumowe (np. „sz”, „ch”, „cz”) mają bardzo wysoki ZCR i brak F_0.

6 Porównanie nagrań różnych mówców

Analizowano nagrania dziewięciu osób (8 mężczyzn i 1 kobieta).

Zaobserwowano następujące różnice:

- dla mówców męskich wartości F_0 były zwykle niższe (ok. 80–150 Hz),
- dla mówczyni (*speaker*_02) wartości F_0 były wyższe (ok. 200–300 Hz),
- przebiegi RMS i STE były podobne niezależnie od płci,
- ZCR zależał głównie od typu głoski, a nie od mówcy.

Dla tych samych słów (np. „kot”, „pies”) różnice dotyczyły głównie:

- wysokości tonu podstawowego,
- długości poszczególnych segmentów,
- poziomu energii.

Table 2: Wartości F_0 dla różnych mówców

Speaker	**Płeć**	F_0 **[Hz]**
speaker_01	mężczyzna	90–140
speaker_02	kobieta	180–280
speaker_03	mężczyzna	80–150
speaker_04	mężczyzna	90–145

7 Wnioski końcowe

W ramach projektu opracowano aplikację okienkową umożliwiającą analizę sygnału audio w dziedzinie czasu. Program pozwala na wczytywanie plików WAV, segmentację sygnału na ramki, obliczanie podstawowych cech krótkookresowych, wykrywanie ciszy oraz estymację częstotliwości tonu podstawowego z wykorzystaniem metod autokorelacji i AMDF. Dodatkowo zaimplementowano możliwość wizualizacji wyników oraz eksportu danych do pliku CSV.

Uzyskane wyniki są zgodne z oczekiwaniami wynikającymi z teorii przetwarzania sygnałów i fonetyki. Cechy takie jak RMS i STE poprawnie odzwierciedlają lokalną energię sygnału, osiągając wyższe wartości w fragmentach dźwięcznych, natomiast współczynnik ZCR umożliwia skuteczne rozróżnianie fragmentów o charakterze szumowym i periodycznym. Estymacja częstotliwości tonu podstawowego pozwala na identyfikację fragmentów sygnału zawierających strukturę quasi-okresową, charakterystyczną dla głosek dźwięcznych.

Przeprowadzone eksperymenty wykazały, że połączenie kilku cech krótkookresowych umożliwia efektywną analizę struktury sygnału mowy, w tym rozróżnianie fragmentów ciszy, głosek dźwięcznych oraz bezdźwięcznych. Zastosowane metody, mimo swojej względnej prostoty, pozwalają na uzyskanie intuicyjnych i interpretowalnych wyników, co czyni je przydatnymi w podstawowej analizie sygnału audio.

Opracowane rozwiązanie stanowi dobrą bazę do dalszego rozwoju. Możliwe kierunki rozszerzenia obejmują implementację cech clip-level, bardziej zaawansowane metody estymacji tonu podstawowego, a także klasyfikację sygnałów (np. mowa/muzyka). Dzięki modularnej strukturze aplikacji możliwe jest stosunkowo łatwe rozszerzanie jej funkcjonalności o kolejne elementy analizy sygnału.