Politechnika Warszawska
Wydział Matematyki
i Nauk Informacyjnych

Analiza Częstotliwościowa

Raport z projektu

Analiza i przetwarzanie dźwięku

Małgorzata Dżaman

nr indeksu: 327241

WARSZAWA 2025

Contents

1 Wstęp **3**

2 Opis aplikacji **3**

3 Przebieg eksperymentów **4**

4 Wyniki eksperymentów **5**

4.1 Test 1 – FFT dla różnych fragmentów słowa 5

4.2 Test 2 – FFT całego sygnału i pojedynczej ramki 5

4.3 Test 3 – wpływ funkcji okienkowych 6

4.4 Test 4 – wpływ długości ramki 7

4.5 Test 5 – centroid, bandwidth, flatness i crest 7

4.6 Test 6 – Band Energy Ratio 8

4.7 Test 7 – spektrogram 9

4.8 Test 8 – cepstrum i częstotliwość podstawowa 10

5 Odpowiedzi na pytania problemowe i Wnioski końcowe **11**

5.1 Jak wyglądają parametry w dziedzinie częstotliwości dla różnych głosów i głosek? 11

5.2 Jak zmienia się ton podstawowy u jednego lektora? 12

5.3 W jakim zakresie zmienia się F_0 wśród różnych osób? 12

5.4 Czy w samogłoskach można zaobserwować formanty? 12

5.5 Czy formanty różnią się w różnych realizacjach tego samego fonemu? . . . 13

5.6 Czy formanty różnią się w samogłoskach różnych osób? 13

5.7 Czy w FFT i spektrogramie da się zauważyć różnice pomiędzy samogłoskami i spółgłoskami? 13

5.8 Czy widać wpływ funkcji okienkowych? 14

5.9 Podsumowanie końcowe 14

1 Wstęp

Analiza sygnału audio w dziedzinie częstotliwości jest jednym z podstawowych narzędzi wykorzystywanych w przetwarzaniu mowy. W przeciwieństwie do analizy w dziedzinie czasu, która pokazuje zmiany amplitudy sygnału w kolejnych chwilach, analiza częstotliwościowa pozwala określić, jakie składowe częstotliwościowe występują w sygnale i jak zmieniają się one w czasie.
Sygnał mowy ma charakter niestacjonarny, dlatego jego właściwości zmieniają się w trakcie wypowiedzi. Z tego powodu w projekcie zastosowano analizę krótkookresową, polegającą na podziale sygnału na krótkie ramki. Dla każdej ramki można następnie obliczyć transformatę Fouriera, cechy widmowe oraz spektrogram.
W projekcie analizowano między innymi:

- widmo amplitudowe FFT całego sygnału i pojedynczych ramek,
- wpływ funkcji okienkowych na widmo,
- wpływ długości ramki na rozdzielczość częstotliwościową,
- cechy widmowe: centroid, bandwidth, spectral flatness, crest factor,
- rozkład energii w pasmach częstotliwości,
- spektrogramy dla słów i zdań,
- estymację tonu podstawowego F_0 z wykorzystaniem cepstrum.

Celem projektu było rozszerzenie wcześniejszej aplikacji do analizy sygnału audio w dziedzinie czasu o część częstotliwościową. Dzięki temu możliwe było porównanie fragmentów dźwięcznych i bezdźwięcznych nie tylko na podstawie RMS, STE i ZCR, ale również na podstawie struktury widmowej.

2 Opis aplikacji

Aplikacja analizy częstotliwościowej została wykonana poprzez rozszerzenie pierwszej aplikacji dotyczącej analizy sygnału audio w czasie.
Elementy interfejsu, które zostały dodane do podstawowej wersji aplikacji to:

- zakładka FFT,
- zakładka pokazująca wpływ okna na ramkę w czasie,
- zakładka cepstrum,
- zakładka spektrogramu,
- pola wyboru długości ramki i overlapu,
- lista wyboru funkcji okienkowej,
- panel z wartościami cech widmowych.

Na poniższym zdjęciu1 zaznaczono na czerwono elementy, które pojawiły się w aplikacji częstotliwościowej

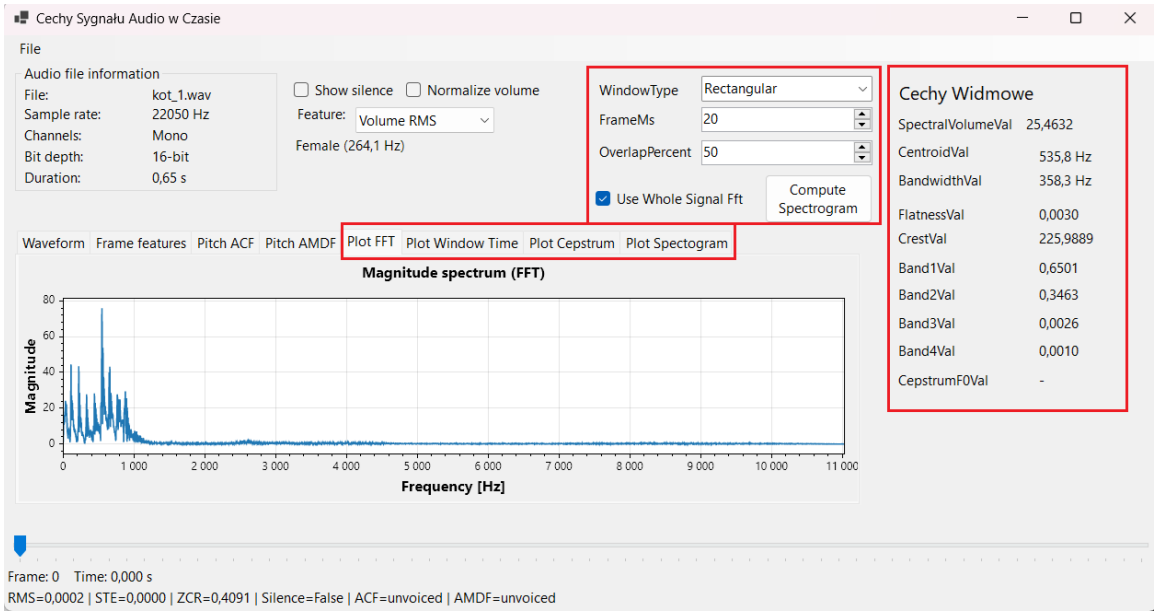

Figure 1: Interfejs aplikacji rozszerzonej o analizę częstotliwościową.

3 Przebieg eksperymentów

Eksperymenty przeprowadzono według następującego schematu:

1. wczytanie pliku WAV,
2. wybór ramki lub całego sygnału,
3. wybór długości ramki, overlapu i funkcji okienkowej,

4. obliczenie FFT oraz cech widmowych,

5. wykonanie spektrogramu,

6. obliczenie cepstrum i estymacja F_0,

7. porównanie wyników dla samogłosek, spółgłosek, słów i zdań.

4 Wyniki eksperymentów

4.1 Test 1 – FFT dla różnych fragmentów słowa

Pierwszy test polegał na analizie FFT dla różnych ramek słowa *kot*: początku, środka oraz końca nagrania. Celem było sprawdzenie, czy widmo zmienia się w zależności od analizowanego fragmentu.

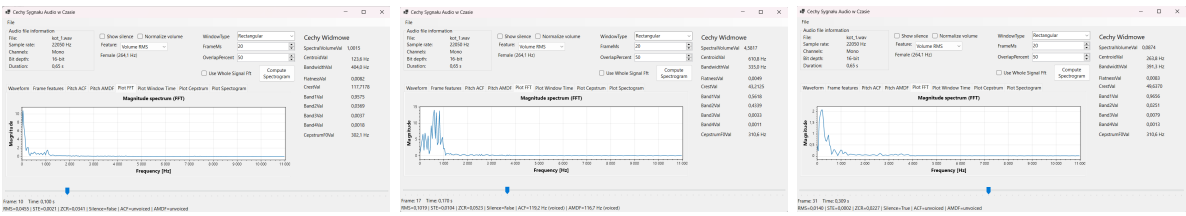

(a) Początek słowa (b) Samogłoska (c) Koniec słowa

Figure 2: Porównanie widma FFT dla różnych ramek słowa *kot*.

Dla początku i końca słowa odpowiadających odpowiednio spółgłosce bezdźwięcznej "k" i spółgłosce "t" widmo miało charakter bardziej rozproszony, bez wyraźnej struktury harmonicznej. W środkowej części sygnału, odpowiadającej samogłosce, widoczne były wyraźne harmoniczne oraz koncentracja energii w niższych częstotliwościach. Uzyskane wyniki potwierdzają, że analiza FFT pozwala rozróżniać różne typy głosek na podstawie ich charakterystyki widmowej.

4.2 Test 2 – FFT całego sygnału i pojedynczej ramki

W drugim teście porównano FFT całego słowa "alobiri" z FFT pojedynczej ramki zawierającej samogłoskę "o". Poniższe ilustracje 3 przedstawiają wyniki jakie otrzymano.

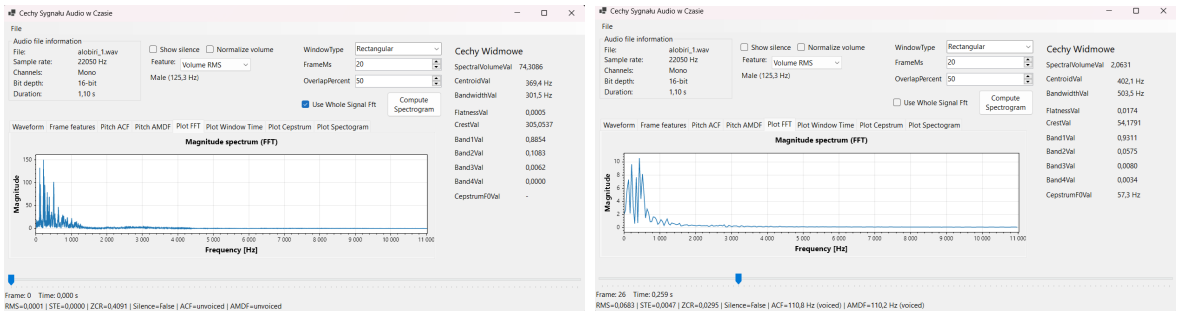

(a) FFT całego sygnału (b) FFT pojedynczej ramki

Figure 3: Porównanie FFT całego sygnału i FFT wybranej ramki.

Porównanie FFT całego sygnału oraz FFT pojedynczej ramki wykazało istotne różnice. Widmo całego sygnału zawiera sumę wszystkich składowych częstotliwościowych obecnych w nagraniu, co prowadzi do bardziej złożonej i mniej czytelnej struktury. Natomiast analiza pojedynczej ramki pozwala na uzyskanie bardziej przejrzystego widma, odpowiadającego lokalnym właściwościom sygnału, np. fragmentowi samogłoskowemu. W szczególności dla fragmentów dźwięcznych widoczne są wyraźne harmoniczne, które nie są tak dobrze rozróżnialne w widmie całego sygnału. Potwierdza to konieczność stosowania analizy krótkookresowej w przetwarzaniu mowy.

4.3 Test 3 – wpływ funkcji okienkowych

W kolejnym teście porównano wpływ różnych funkcji okienkowych na ramkę sygnału oraz jej widmo. Badano okno prostokątne, trójkątne, Hamminga, Hanna i Blackmana. Na poniższych ilustracjach 4 zoobrazowano porównanie okna prostokątnego i okna Hamminga

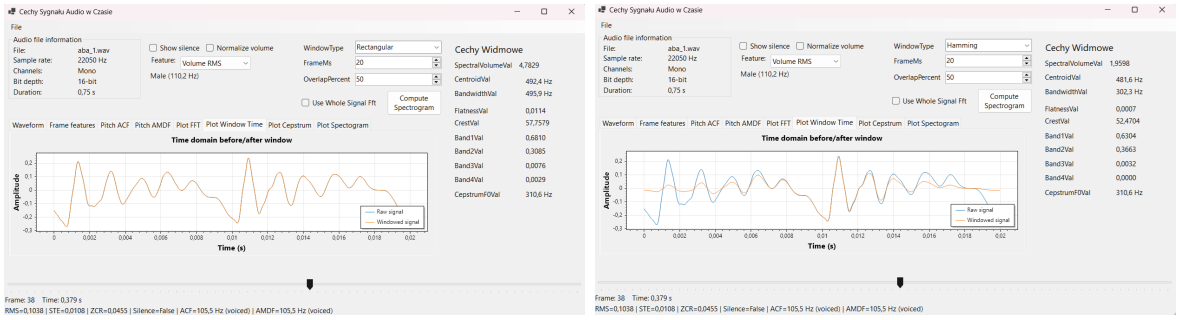

(a) Okno prostokątne (b) Okno Hamminga

Figure 4: Wpływ funkcji okienkowej na ramkę sygnału.

Okno prostokątne praktycznie nie zmienia sygnału, natomiast okna Hamminga, Hanna

i Blackmana zmniejszają amplitudę na brzegach ramki. W widmie prowadzi to do redukcji przecieku widmowego. Efekt w przypadku mowy może być subtelny, ponieważ analizowany fragment samogłoskowy jest dość regularny, jednak różnice widoczne są w zmniejszeniu drobnych składowych ubocznych oraz zmianie wartości cech widmowych.

4.4 Test 4 – wpływ długości ramki

W teście 4 porównano ramki o długości 10 ms, 20 ms i 40 ms dla tego samego fragmentu samogłoskowego - samogłosce "o" słowa "samochód". Na ilustracji 5 pokazano uzyskane rezultaty.

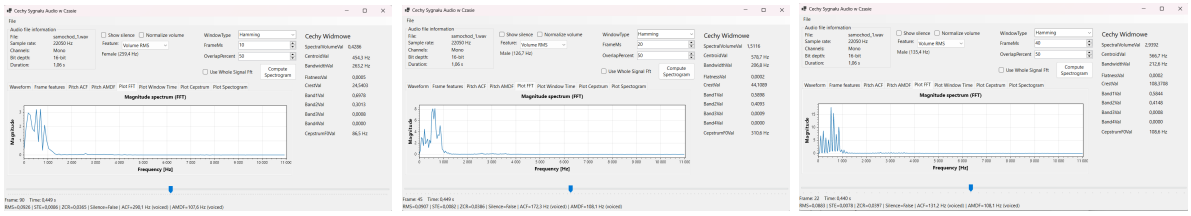

(a) 10 ms (b) 20 ms (c) 40 ms

Figure 5: Wpływ długości ramki na widmo FFT.

Porównano wpływ długości ramki na wynik analizy częstotliwościowej dla tego samego fragmentu samogłoskowego. Dla ramki 10 ms widmo było mniej stabilne, a estymacja częstotliwości podstawowej F_0 była bardziej podatna na błędy. Dla ramek 20 ms i 40 ms widmo miało wyraźniejszą strukturę harmoniczną, a wartości częstotliwości podstawowej były bardziej stabilne. Wydłużenie ramki poprawia rozdzielczość częstotliwościową FFT, ponieważ transformata jest obliczana dla większej liczby próbek. Jednocześnie dłuższa ramka pogarsza rozdzielczość czasową, dlatego w praktyce należy dobrać kompromis między dokładnością w dziedzinie częstotliwości a lokalizacją zmian w czasie.

4.5 Test 5 – centroid, bandwidth, flatness i crest

W tym teście porównano fragment samogłoskowy *a* w logatomie *aba* oraz spółgłoskę szumową w słowie *chrząszcz*. Wyniki przedstawiono na ilustracji 6 i w tabeli 1

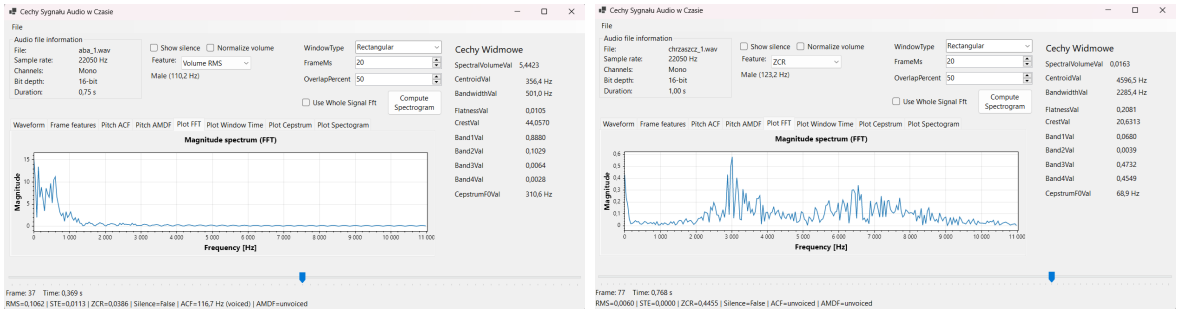

(a) Samogłoska a (b) Fragment szumowy

Figure 6: Porównanie widma samogłoski i spółgłoski szumowej.

Cecha	Samogłoska a	Spółgłoska szumowa
Centroid [Hz]	ok. 356	ok. 4597
Bandwidth [Hz]	ok. 501	ok. 2285
Flatness	ok. 0.01	ok. 0.2
Crest factor	ok. 45	ok. 20
Charakter widma	harmoniczne	szumowe

Table 1: Porównanie cech widmowych dla samogłoski i spółgłoski szumowej.

Analiza dwóch różnych fragmentów sygnału (samogłoski i spółgłoski szumowej) pokazuje wyraźne różnice w cechach widmowych. Dla samogłoski wartości spectral centroid i bandwidth są znacznie niższe, co oznacza koncentrację energii w niższych częstotliwościach. Dodatkowo niski spectral flatness oraz wysoki crest factor wskazują na obecność wyraźnych harmonicznych. W przypadku spółgłoski szumowej "sz" centroid oraz bandwidth są dużo wyższe, co świadczy o rozproszeniu energii w szerokim zakresie częstotliwości. Wyższa wartość flatness oraz niższy crest factor potwierdzają szumowy charakter sygnału.

4.6 Test 6 – Band Energy Ratio

W teście porównano rozkład energii w pasmach:

$$Band1 : 0-630\,\text{Hz}, \quad Band2 : 630-1720\,\text{Hz}, \quad Band3 : 1720-4400\,\text{Hz}, \quad Band4 : 4400-11025\,\text{Hz}.$$

Table 2: Porównanie udziału energii w pasmach.

Sygnał	Band1	Band2	Band3	Band4
Samogłoska *a*	0.112	0.879	0.008	0.002
Spółgłoska szumowa	0.186	0.026	0.315	0.473
Ramka ze zdania	0.054	0.924	0.020	0.020
Całe zdanie	0.433	0.536	0.020	0.011

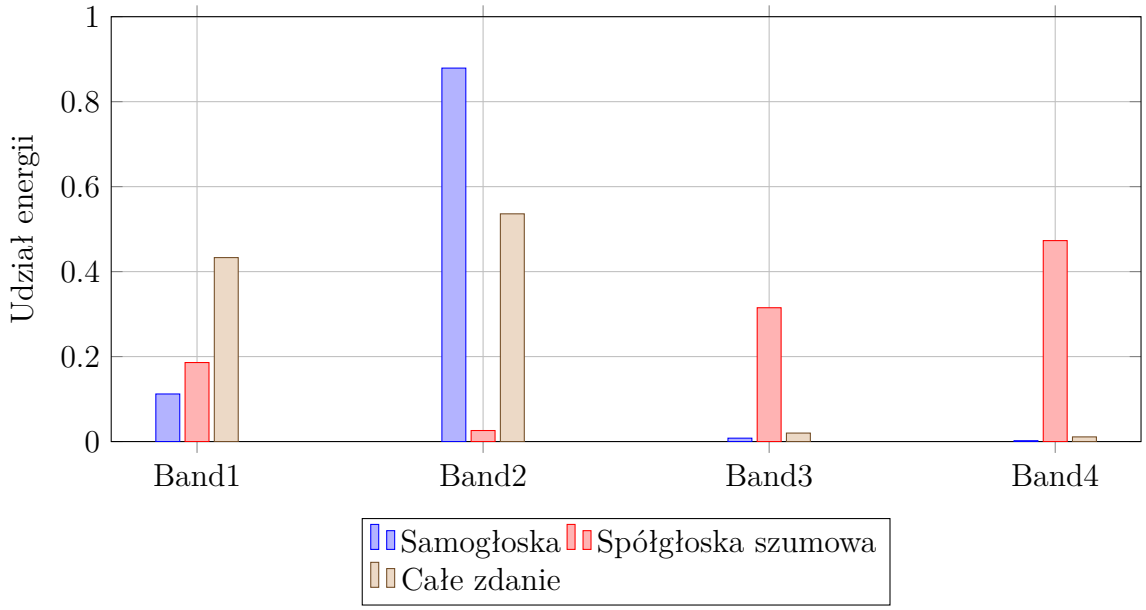

Figure 7: Rozkład energii w pasmach dla różnych typów sygnału.

Dla samogłoski największa część energii znajdowała się w niskich pasmach, szczególnie w Band2. Dla spółgłoski szumowej energia przesunęła się do wysokich pasm Band3 i Band4. Dla całego zdania rozkład był mieszany, ponieważ zdanie zawiera zarówno samogłoski, jak i spółgłoski.

4.7 Test 7 – spektrogram

Spektrogram przedstawia zmianę widma w czasie. Wykonano spektrogramy dla słowa *kot*, słowa *chrząszcz* oraz zdania *Ala ma rudego kota*. Dodatkowo sprawdzono wpływ overlapu.

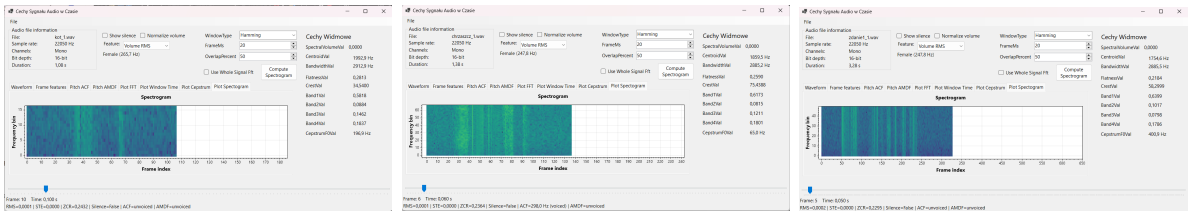

(a) *kot* (b) *chrząszcz* (c) zdanie

Figure 8: Spektrogramy dla różnych typów nagrań, overlap 50%.

W spektrogramie samogłosek widoczne są bardziej uporządkowane pasma energii. Dla słowa *chrząszcz* obraz jest bardziej rozproszony, co odpowiada szumowemu charakterowi głosek takich jak *sz*, *cz*, *ch*. Dla zdania obserwowany jest układ mieszany.

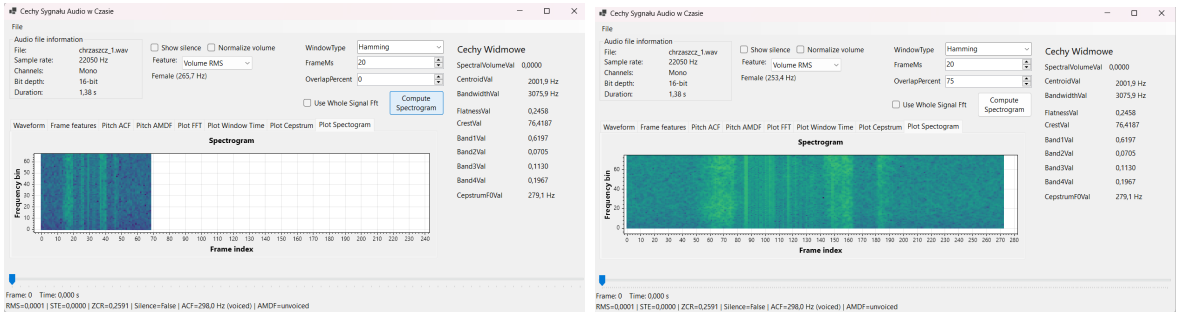

(a) Overlap 0% (b) Overlap 75%

Figure 9: Wpływ overlapu na spektrogram.

Przy overlapie 0% spektrogram jest bardziej blokowy i mniej ciągły. Przy overlapie 75% obraz jest gładszy, ponieważ kolejne ramki silniej na siebie nachodzą. W praktyce overlap 50% stanowi kompromis pomiędzy czytelnością a liczbą obliczeń.

4.8 Test 8 – cepstrum i częstotliwość podstawowa

W teście cepstralnym porównano fragment samogłoskowy wypowiedziany przez kobietę i mężczyznę.

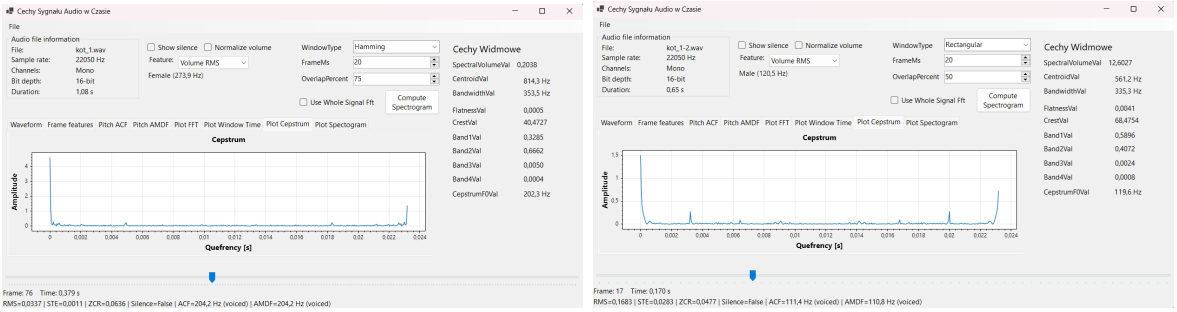

(a) Głos kobiecy (b) Głos męski

Figure 10: Cepstrum dla głosu kobiecego i męskiego.

Table 3: Porównanie częstotliwości podstawowej wyznaczonej z cepstrum.

Mówca	Płeć	F_0 [Hz]
speaker_02	kobieta	ok. 202
wybrany mówca męski	mężczyzna	ok. 119

Uzyskane wyniki są zgodne z oczekiwaniami: głos kobiecy miał wyższą częstotliwość podstawową niż głos męski. W cepstrum widoczny był pik odpowiadający okresowi tonu podstawowego.

5 Odpowiedzi na pytania problemowe i Wnioski końcowe

5.1 Jak wyglądają parametry w dziedzinie częstotliwości dla różnych głosów i głosek?

Na podstawie wykonanych testów widać, że parametry częstotliwościowe bardzo mocno zależą od tego, jaki fragment mowy analizujemy. Największe różnice zostały wykryte przy porównaniu samogłoski *a* z logatomu *aba* oraz fragmentu szumowego ze słowa *chrząszcz*. Dla samogłoski widmo było bardziej uporządkowane, miało wyraźne piki i energię skupioną głównie w niższych częstotliwościach. Wartość centroidu była wtedy znacznie niższa. Dla fragmentu szumowego sytuacja była odwrotna. Widmo było bardziej rozlane, mniej regularne i energia pojawiała się również w wyższych pasmach. Potwierdziły to wartości

cech widmowych: centroid i bandwidth były dużo większe niż dla samogłoski, a flatness także wzrosło, co zgadza się z tym, że taki fragment bardziej przypomina szum.

5.2 Jak zmienia się ton podstawowy u jednego lektora?

W trakcie testów zauważyłam, że ton podstawowy nie jest stały nawet dla jednego nagrania. Wartość F_0 zależy od tego, w której ramce ustawiony jest suwak. Dla ramek odpowiadających samogłoskom wartości były stabilniejsze, tzn. ok. 200 Hz dla głosu kobiecego oraz ok. 100–120 Hz dla głosu męskiego.

Natomiast dla ramek odpowiadających ciszy albo spółgłoskom bezdźwięcznym estymacja F_0 często nie miała sensownej wartości albo była oznaczana jako *unvoiced*. W praktyce oznacza to, że tonu podstawowego najlepiej szukać w samogłoskach, bo tam sygnał jest okresowy.

5.3 W jakim zakresie zmienia się F_0 wśród różnych osób?

W teście cepstrum porównane zostały głos kobiecy i męski. Dla głosu kobiecego wartość wyniosła ok. 202 Hz, a dla głosu męskiego ok. 119 Hz. Różnica była więc dobrze widoczna.

W innych testach aplikacja również często klasyfikowała głos kobiecy jako wyższy, a męski jako niższy. Nie są to oczywiście wartości identyczne dla każdej ramki, bo zależą od konkretnego fragmentu wypowiedzi, ale ogólna tendencja, która się pojawiła to: głos kobiecy miał wyższe F_0, a głos męski niższe.

5.4 Czy w samogłoskach można zaobserwować formanty?

Tak, w samogłoskach można zauważyć formanty. W aplikacji były one obserwowane głównie jako lokalne wzmocnienia widma oraz jaśniejsze pasma na spektrogramie.

Najlepiej było to widoczne dla samogłosek, np. w logatomie *aba* albo w środkowej części słowa *kot*. W tych fragmentach widmo nie było przypadkowe, tylko miało uporządkowaną strukturę. Formanty można rozumieć jako pasma częstotliwości, w których energia samogłoski jest szczególnie duża. Wynikają one z rezonansów układu mowy, czyli z tego, w jaki sposób ułożone są język, usta czy jama ustna.

5.5 Czy formanty różnią się w różnych realizacjach tego samego fonemu?

Na podstawie obserwacji wykresów można powiedzieć, że tak. Nawet jeśli analizowana była ta sama samogłoska, np. *a*, to jej widmo nie zawsze wyglądało identycznie. Zależało to od tego, która ramka została wybrana oraz od sposobu w jaki dźwięk został wypowiedziany. Różnice nie muszą być bardzo duże, ale można zauważyć przesunięcia lokalnych maksimów i zmianę ich amplitudy. Wynika to z tego, że człowiek nie wypowiada dwóch słów,a wię też dwóch głosek idealnie tak samo. Wpływ na to mają m.in tempo mówienia, intonacja czy siła głosu oraz dokładny moment wybranej ramki.

5.6 Czy formanty różnią się w samogłoskach różnych osób?

Tak, widać, że widmo samogłosek zależy od mówcy. Dla różnych osób ta sama samogłoska może mieć podobny ogólny charakter, czyli nadal będzie widoczna struktura harmoniczna i większa energia w niższych pasmach, ale dokładne położenie maksimów może się różnić. Jest to o tyle intuicyjne, ponieważ każda osoba ma trochę inną budowę aparatu mowy. Dlatego u różnych mówców te same samogłoski mogą mieć nieco inne formanty. W testach było też widać, że głos kobiecy i męski różniły się przede wszystkim wysokością tonu podstawowego, ale różnice można było zauważyć również w kształcie widma.

5.7 Czy w FFT i spektrogramie da się zauważyć różnice pomiędzy samogłoskami i spółgłoskami?

Tak, i był to jeden z najbardziej widocznych wyników. Dla samogłosek na wykresie FFT pojawiały się wyraźne piki harmoniczne. Widmo było bardziej regularne, a energia skupiała się głównie w niższych pasmach. W spektrogramie samogłoski dawały bardziej uporządkowane pionowe lub pasmowe struktury.

Dla spółgłosek szumowych, np. fragmentów *sz*, *cz*, *ch* w słowie *chrząszcz*, widmo było dużo bardziej rozproszone. Energia pojawiała się w wyższych częstotliwościach, a na spektrogramie obraz był mniej uporządkowany i bardziej "ziarnisty". Bardzo dobrze potwierdził to test Band Energy Ratio, gdzie dla samogłoski dominowały niskie pasma, a dla fragmentu szumowego znacząco wzrosły Band3 i Band4.

5.8 Czy widać wpływ funkcji okienkowych?

Wpływ funkcji okienkowych był widoczny głównie w zakładce pokazującej ramkę przed i po oknie. Dla okna prostokątnego sygnał praktycznie się nie zmieniał. Dla okna Hamminga, Hanna, Blackmana i trójkątnego brzegi ramki były wyraźnie wygaszane, co wpływało na kształt widma FFT analizowanego fragmentu sygnału.

5.9 Podsumowanie końcowe

Przeprowadzone eksperymenty pokazały, że analiza częstotliwościowa dobrze uzupełnia analizę w dziedzinie czasu. Na podstawie FFT, spektrogramu i cech widmowych można było zauważyć różnice między samogłoskami, spółgłoskami szumowymi, pojedynczymi słowami oraz zdaniami.

Samogłoski miały bardziej uporządkowane widmo, wyraźniejsze piki harmoniczne i większą energię w niższych pasmach. Spółgłoski szumowe miały widmo bardziej rozproszone oraz większy udział energii w wyższych częstotliwościach. Długość ramki, overlap i funkcja okienkowa miały zauważalny wpływ na wyniki analizy.

Na podstawie testów można stwierdzić, że rozszerzona aplikacja pozwala w czytelny sposób analizować sygnał mowy w dziedzinie częstotliwości i dobrze pokazuje różnice pomiędzy różnymi typami fragmentów nagrań.